DASK 0. Install

대스크 설치에는 conda와 pip 2가지 방법이 있는데 pip는 에러가 생길 수 있으므로 conda로 설치하는 걸 추천합니다

conda install -y dask -> Normal 버전

conda install dask -c conda -forge -> all common dependencis 포함 판다스 넘파이, 그리고 모든 대스크 패키지

conda install dask-core -> 대스크 모듈을 돌리기 위한 최소한으로 필요한 디펜던시 세트 (python -m pip install dask랑 비슷함)

Dask 1. 대스크 Delayed를 사용한 병령화와 visualize, compute

Dask는 파이썬을 기반으로, Pandas를 사용하는 데이터 분석가, 엔지니어는 쉽게 사용할 수 있도록 구현되어 있으며 대량의 데이터를 다루는데 특화되어있습니다.

```
# 기본 함수

from time import sleep

def inc(x):
    sleep(5)
    return x + 1

def add(x, y):
    sleep(5)
    return x + y
```

```
%%time

x = inc(1)
y = inc(2)
z = add(x, y)
```

```
CPU times: user 78.6 ms, sys: 6.51 ms, total: 85.1 ms
Wall time: 15 s
```

파이썬에서는 x > y > z 순으로 순차적으로 실행하기 때문에 15초가 걸림

```
import dask.delayed as delayed

@delayed

def inc(x):
    sleep(5)
    return x + 1


@delayed

def add(x, y):
    sleep(5)
    return x + y
```

Dask의 delayed 함수를 사용하기 위하여 (@)데코레이터를 사용합니다만, 파이썬과 비교를 하기 위해 기본 함수를 사용하여 비교하기를 가정합니다. 데코레이션을 사용하지 않고 사용하기 위해서는 함수 형태로 사용해주시면 됩니다.

```
%%time

x = delayed(inc)(1)
y = delayed(inc)(2)
z = delayed(add)(x, y)
```

```
CPU times: user 0 ns, sys: 420 µs, total: 420 µs
Wall time: 417 µs
```

z는 지연(Delayed) 객체입니다. 모든 함수에 대한 참조와 해당 입력 및 서로 간의 관계를 포함하여 최종 결과를 계산하는 데 필요한 모든 것을 갖고 있습니다.

```
z #z가 최종 결과를 산출하는데 필요한 모든 정보를 가지고 있으며 이를 graphviz를 사용해 시각화 할 수
```

```
Delayed('add-e95e649b-4101-4568-905c-b550bc29ced2')
```

```
z.visualize()
```

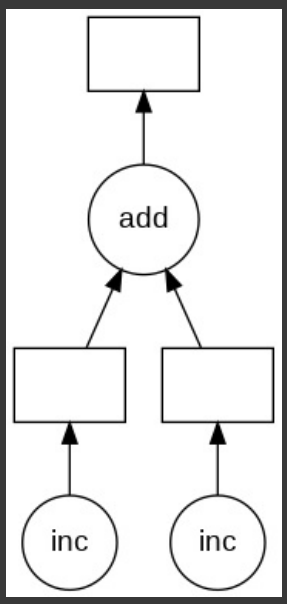

최종 결과를 산출하기 위해서는 compute함수를 사용합니다.

```
%%time

z.compute()
```

```
CPU times: user 57 ms, sys: 8.34 ms, total: 65.4 ms
Wall time: 10 s
5
```

x와 y를 병렬화하여 동시 실행 후 z를 실행하기 때문에 시간은 10초가 걸렸습니다.

동시 실행을 하기 때문에 단순 비교임에도 sleep(5) 만큼의 차이를 보였습니다

Dask 2. Delayed 함수를 사용한 For문 계산

```
data = [1,2,3,4,5]
```

```
%%time

results = []

for x in data:
    y = delayed(inc)(x)
    results.append(y)
```

```
 8 total = delayed(sum)(results)
 9
10 total.compute()
```

```
CPU times: user 79.5 ms, sys: 11.1 ms, total: 90.5 ms
Wall time: 15 s
20
```

```
1 total.visualize()
```

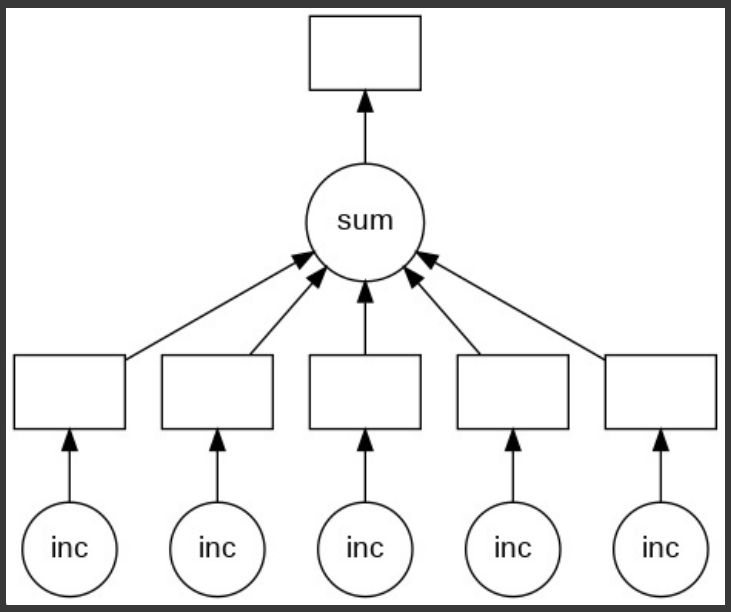

Delayed 연산을 통해 총 5개의 데이터 처리를 위한 for문 계산이 5초 소요되었습니다. 동시에 계산하기 때문에 sleep(5) 만큼의 시간만 소요되었습니다.

Dask의 delayed 함수를 사용하면 Python의 기본 연산을 조금 더 효율적으로 진행할 수 있습니다.

```
 1 %%time
 2
 3 results = []
 4
 5 for x in data:
 6     y = inc(x)
 7     results.append(y)
 8 total = sum(results)
 9
10 total.compute()
```

```
CPU times: user 87.2 ms, sys: 12.4 ms, total: 99.6 ms
Wall time: 15 s
20
```

Dask 3. 대스크 Redshift 및 DB,S3,HDFS, parquet, CSV 데이터 불러오기

업무에서 사용하는 각종 DB로부터 데이터를 불러와 작업하는 방법을 알아보겠습니다.

기본적으로 Redshift에서 데이터를 불러오는 방법을 소개하나, 응용하여 다른 종류의 데이터베이스로부터 데이터를 불러올 수 있습니다.

```
 1 # Redshift 연결 정보
 2 username = 'dataiger'
 3 password = 'dataiger'
 4 host = 'dataiger-redshift:5439'
 5 database = 'dataiger'
 6
 7 connection_string = f'postgresql://{username}:{password}@{host}/{database}'
 8
```

위의 코드처럼 데이터베이스의 정보를 입력해줍니다. 그리고 다른 종류의 데이터베이스를 사용하신다면 postgresql 부분을 변경하여 사용하시면 됩니다.

```
# DB 데이터 불러오기
import dask.dataframe as dd

df = dd.read_sql_table(con = connection_string,
                       schema = '스키마명',
                       table_name = '테이블명',
                       index_col = '인덱스로 설정할 컬럼명',
                       columns = ['컬럼1', '컬럼2'], # 없으면 전체 컬럼
                       npartitions = 10)
```

read_sql_table의 매개변수를 자세히 보고 싶으신 분은 아래의 링크에서 확인하시면 됩니다.

https://docs.dask.org/en/latest/generated/dask.dataframe.read_sql_table.html

아마존의 S3와 하둡 파일 시스템에서도 데이터를 쉽게 불러올 수 있습니다. S3 파일 경로와 HDFS 파일 경로를 입력해주면 쉽게 불러올 수 있습니다.

```
# S3
s3_data = dd.read_csv('s3://bucket/path/*.csv', dtype=dtypes, usecols=usecols)

# HDFS
hdfs_data = dd.read_csv('hdfs://filepath/*.csv', dtype=dtypes, usecols=usecols)

```

dtype과 usecols 매개변수는 사용하지 않아도 무방하나, 대스크는 기본적으로 데이터 타입이 중요하기 때문에 에러를 내지 않기 위해서 명시적으로 타입을 지정해줄 수 있습니다. 또한 사용할 컬럼을 명시적으로 지정하는 기능을 지원합니다.

```

```

Parquet 데이터 불러오기

대스크와 함께 parquet 파일을 사용하기 위해서는 fastparquet 또는 pyarrow 라이브러리를 설치하셔야 합니다

```
# 라이브러리 설치
# pip install fastparquet
# pip install pyarrow

# parquet 데이터 불러오기
parquet_data = dd.read_parquet('*.parquet')

# S3 parquet 불러오기
s3_parquet_data = dd.read_parquet('s3://bucket/path/*.parquet')

# HDFS parquet 불러오기
hdfs_parquet_data = dd.read_parquet('hdfs://filepath/*.parquet')


```

Dask 3. 대스크 compute()와 persist()

숨겨진 셀 10개

Dask 4. Dataframe과 keras(기초)

Dask 4. Dataframe과 Keras(추가)

```
# 1 대스크 데이터 프레임
# 사용 데이터: NYC Flights Data(뉴욕 3개 지역 공항에서 출발하는 항공편)
```

```
import urllib
import tarfile

# 뉴욕에서 출발하는 항공편 데이터 다운로드
url = "https://storage.googleapis.com/dask-tutorial-data/nycflights.tar.gz"
filename, headers = urllib.request.urlretrieve(url, '/content/nycflights.tar.gz')

# 압축 해제 코드
with tarfile.open(filename, mode='r:gz') as flights:
    flights.extractall('/content/')
```

api로 제공되는 데이터를 다운로드하여줍니다.

만일, 아래와 같은 에러가 난다면 SSL 코드를 실행 후 다운로드하여줍니다.

```
# SSL 에러 발생시 해결방법
import requests
requests.packages.urllib3.disable_warnings()
import ssl

try:
    _create_unverified_https_context = ssl._create_unverified_context
except AttributeError:
    # Legacy Python that doesn't verify HTTPS certificates by default
    pass
else:
    # Handle target environment that doesn't support HTTPS verification
    ssl._create_default_https_context = _create_unverified_https_context
```

데이터가 준비되었다면 대스크의 데이터 프레임으로 불러오겠습니다.

```
import dask.dataframe as dd

df = dd.read_csv('/content/nycflights/*', parse_dates = {'Date': [0,1,2]})
```

NYC_flights 데이터를 확인해보면, Year, Month, DayofMonth로 날짜가 구분이 되는 것을 확인하실 수 있는데, pandas의 기능인 parse_dates = {'Date': [0, 1, 2]}을 활용하여 Date라는 새로운 컬럼에 Datatime 형식으로 불러올 수 있습니다.

대스크 데이터 프레임의 구조를 확인해보면 위의 이미지와 같이 출력이 됩니다.

npartitions : 파티션 수

int, float, object 등 : 열 데이터 유형

Dask Name : DAG 내부 이름

10 tasks : DAG 노드 수

Pandas의 데이터 프레임과는 다르게 데이터를 불러오지 않으며, 열 데이터의 유형 또한 샘플링을 통해 추정을 한 형태입니다.

유형에 대해 조금 더 자세히 보겠습니다

```
df.tail()
```

```
---------------------------------------------------------------------------
ValueError                                Traceback (most recent call last)
<ipython-input-21-4add252522c8> in <module>
----> 1 df.tail()
```

```
13 frames
/usr/local/lib/python3.7/dist-packages/dask/dataframe/io/csv.py in coerce_dtypes(df, dtypes)
    282             rule.join(filter(None, [dtype_msg, date_msg]))
    283         )
--> 284         raise ValueError(msg)
    285
    286

ValueError: Mismatched dtypes found in `pd.read_csv`/`pd.read_table`.

+----------------+---------+----------+
| Column         | Found   | Expected |
+----------------+---------+----------+
| CRSElapsedTime | float64 | int64    |
| TailNum        | object  | float64  |
+----------------+---------+----------+

The following columns also raised exceptions on conversion:

- TailNum
  ValueError("could not convert string to float: 'N54711'")

Usually this is due to dask's dtype inference failing, and
*may* be fixed by specifying dtypes manually by adding:

dtype={'CRSElapsedTime': 'float64',
       'TailNum': 'object'}

to the call to `read_csv`/`read_table`.

SEARCH STACK OVERFLOW
```

대스크의 데이터 프레임으로 불러온 데이터에서 ValueError가 발생합니다. 이는 위에서 설명했듯이 샘플링을 통해 추정한 데이터의 타입이 실제로는 맞지 않아 발생하는 문제로, parquet 형태처럼 데이터 타입까지 같이 저장되는 형식이 아니라면 데이터 유형에 신경을 써주셔야 합니다.

```
df = dd.read_csv('/content/nycflights/*',
                 parse_dates = {'Date': [0, 1, 2]},
                 dtype={'CRSElapsedTime': 'float64',
                        'TailNum': 'object'}
                )
```

```
df
```

Dask DataFrame Structure:

	Date	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	UniqueCarrier	FlightNum	Tai
npartitions=10									
	datetime64[ns]	int64	float64	int64	float64	int64	object	int64	o
	...	...	...	...	...	...	...	...	
...	...	...	...	...	...	...	...	...	
	...	...	...	...	...	...	...	...	
	...	...	...	...	...	...	...	...	

Dask Name: read-csv, 10 tasks

```
df.tail()
```

	Date	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	UniqueCarrier	FlightNum	TailNum	ActualEla
269176	1999-12-27	1	1645.0	1645	1830.0	1901	UA	1753	N516UA	
269177	1999-12-28	2	1726.0	1645	1928.0	1901	UA	1753	N504UA	
269178	1999-12-29	3	1646.0	1645	1846.0	1901	UA	1753	N592UA	

269179	1999-12-30	4	1651.0	1645	1908.0	1901	UA	1753	N575UA
269180	1999-12-31	5	1642.0	1645	1851.0	1901	UA	1753	N539UA

5 rows × 21 columns

위에서 데이터 프레임에 대해 가볍게 살펴보았습니다.

Dask의 장점은 Pandas와 동일하게 여러 ML 라이브러리와 연동하여 사용할 수 있는 점입니다.

지금은 아주 간단한 Keras 모델링을 해보도록 하겠습니다.

```
df_train = df[['CRSDepTime',  'CRSArrTime', 'Cancelled']]
```

위에서 불러온 df에서 출발과 도착시간을 통해 취소여부에 대해 예측하는 모델을 만들어 보겠습니다.

```
from dask.diagnostics import ProgressBar

with ProgressBar():
  print(df_train.isnull().sum().compute())
```

```
[########################################] | 100% Completed |  6.9s
CRSDepTime    0
CRSArrTime    0
Cancelled     0
dtype: int64
```

총 269,180행의 데이터의 Null 값 여부가 4초 만에 계산되었고, 따로 전처리를 하지 않아도 될 것 같습니다.

모델을 만들어 학습까지 진행해보도록 하겠습니다.

```
from keras.models import Sequential
from keras.layers import Dense

model = Sequential()
# input_dim=df_train.iloc[:, :-1] : Cancelled 컬럼을 제외한 dimension
model.add(Dense(20, input_dim=df_train.iloc[:, :-1].shape[1], activation='relu'))
model.add(Dense(1,activation='sigmoid'))

model.compile(loss='binary_crossentropy', optimizer='sgd',)
```

```

```

```

```

```
Epoch 1/10
10203/10203 [==============================] - 17s 2ms/step - loss: 2.3073
Epoch 2/10
```

```
10203/10203 [==============================] - 17s 2ms/step - loss: 0.1247
Epoch 3/10
10203/10203 [==============================] - 17s 2ms/step - loss: 0.1247
Epoch 4/10
10203/10203 [==============================] - 17s 2ms/step - loss: 0.1247
Epoch 5/10
10203/10203 [==============================] - 17s 2ms/step - loss: 0.1247
Epoch 6/10
10203/10203 [==============================] - 18s 2ms/step - loss: 0.1247
Epoch 7/10
10203/10203 [==============================] - 17s 2ms/step - loss: 0.1247
Epoch 8/10
10203/10203 [==============================] - 16s 2ms/step - loss: 0.1247
Epoch 9/10
10203/10203 [==============================] - 16s 2ms/step - loss: 0.1247
Epoch 10/10
10203/10203 [==============================] - 16s 2ms/step - loss: 0.1247
<keras.callbacks.History at 0x7f67dd31c490>
```

빅데이터를 사용할 때에는 generator와 compute()를 사용하여 validation을 적용하여 사용하면 됩니다.

참고자료

https://mindscale.kr/course/python-ds/5/

https://dataiger.tistory.com/4?category=1088132

```
1
```